

次梯度

1 次梯度与次微分

定义 1. \mathbf{g} 是凸函数 f 在 $\mathbf{x} \in \text{dom } f$ 处的次梯度, 如果满足

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \mathbf{g}^T(\mathbf{y} - \mathbf{x}) \quad \forall \mathbf{y} \in \text{dom } f$$

定义 2. $f(\mathbf{x})$ 的次微分 $\partial f(\mathbf{x})$ 是所有次梯度的集合, 即

$$\partial f(\mathbf{x}) = \{\mathbf{g} | \mathbf{g}^T(\mathbf{y} - \mathbf{x}) \leq f(\mathbf{y}) - f(\mathbf{x}), \forall \mathbf{y} \in \text{dom } f\}$$

性质 1. $\partial f(\mathbf{x})$ 是一个闭凸集, 并且可以是空集

注 1. 根据定义, 次微分是一些半空间的交, 因此是一个凸集, 当交集为空时, 该集合为空

性质 2. 如果 $\mathbf{x} \in \text{int dom } f$, 则 $\partial f(\mathbf{x})$ 非空有界

证明. 当 $\mathbf{x} \in \text{int dom } f$ 时, $(\mathbf{x}, f(\mathbf{x}))$ 是凸集 $\text{epi } f$ 的边界, 因此在 $(\mathbf{x}, f(\mathbf{x}))$ 存在一个支撑超平面,

$$\begin{bmatrix} \mathbf{a} \\ b \end{bmatrix}^T \left(\begin{bmatrix} \mathbf{y} \\ t \end{bmatrix} - \begin{bmatrix} \mathbf{x} \\ f(\mathbf{x}) \end{bmatrix} \right) \leq 0, \quad \forall (\mathbf{y}, t) \in \text{epi } f$$

即

$$\mathbf{a}^T \mathbf{y} + bt \leq \mathbf{a}^T \mathbf{x} + bf(\mathbf{x}) \quad \forall (\mathbf{y}, t) \in \text{epi } f$$

若 $b > 0$, 当 $t \rightarrow \infty$ 时不等式不成立

若 $b = 0$, 不等式变为 $\mathbf{a}^T \mathbf{y} \leq \mathbf{a}^T \mathbf{x}$, 令 $\mathbf{y} = \mathbf{x} + \epsilon \mathbf{a}$, 其中 $\epsilon > 0$ 且充分小, 此时不等式将不成立

因此 $b < 0$, 对不等式做一个变形得到

$$-\frac{\mathbf{a}^T}{b}(\mathbf{y} - \mathbf{x}) \leq f(\mathbf{y}) - f(\mathbf{x})$$

由次梯度的定义可以得到, $-\frac{\mathbf{a}^T}{b} \in \partial f(\mathbf{x})$, 因此当 $\mathbf{x} \in \text{int dom } f$ 时, 集合 $\partial f(\mathbf{x})$ 非空。下证 $\partial f(\mathbf{x})$ 有界

当 $\mathbf{x} \in \text{int dom } f$ 时, 取 $r > 0$ 且充分小, 定义如下包含 $2n$ 个点的集合

$$B = \{\mathbf{x} \pm r\mathbf{e}_k | k = 1, \dots, n\} \subset \text{dom } f$$

并定义 $M = \max_{\mathbf{y} \in B} f(\mathbf{y}) < \infty$, 对任意 $\mathbf{g} \in \partial f(\mathbf{x})$, 总存在 $\mathbf{y} \in B$ 满足

$$r\|\mathbf{g}\|_\infty = \mathbf{g}^T(\mathbf{y}-\mathbf{x})$$

若 $\|\mathbf{g}\|_\infty = |g_k|$, 则取 $\mathbf{y} = \mathbf{x} + r\text{sign}(g_k)\mathbf{e}_k$ 。因为 \mathbf{g} 是次梯度, 则满足

$$f(\mathbf{x}) + r\|\mathbf{g}\|_\infty = f(\mathbf{x}) + \mathbf{g}^T(\mathbf{y}-\mathbf{x}) \leq f(\mathbf{y}) \leq M$$

可以得到

$$\|\mathbf{g}\|_\infty \leq \frac{M-f(\mathbf{x})}{r} \quad \forall \mathbf{g} \in \partial f(\mathbf{x})$$

因此 $\partial f(\mathbf{x})$ 是有界的 □

1.1 可次微分计算例子

例 1. 绝对值函数 $f(x) = |x|$

因为 $f(x)$ 只有在 $x = 0$ 处不可导, 因此只需单独考虑这点的次微分, 当 $x > 0$ 时, $f(x) = x$, 导数即为次微分, 此时 $\partial f(x) = 1$, 同理可得当 $x < 0$ 时, $\partial f(x) = -1$ 。当 $x = 0$ 时利用定义求次微分

$$f(y) \geq f(x) + g(y-x)$$

即

$$|y| \geq gy$$

当 $y = 0$ 时, 不等式恒成立, 当 $y > 0$ 时, $g \leq 1$, 当 $y < 0$ 时, $g \geq -1$, 因此当 $x = 0$ 是, $\partial f(x) \in [-1, 1]$ 。综上

$$\partial f(x) = \begin{cases} 1 & x > 0 \\ [-1, 1] & x = 0 \\ -1 & x < -1 \end{cases}$$

例 2. 欧几里得范数 $f(\mathbf{x}) = \|\mathbf{x}\|_2$

1.2 不可次微分例子

例 3. $f: \mathbb{R} \rightarrow \mathbb{R}, \text{dom } f = \mathbb{R}_+$, 其定义如下

$$f(x) = \begin{cases} 1 & x = 0 \\ 0 & x = 1 \end{cases}$$

在 $x = 0$ 处不可次微分

例 4. $f: \mathbb{R} \rightarrow \mathbb{R}, \text{dom } f = \mathbb{R}_+$, 其定义如下

$$f(x) = -\sqrt{x}$$

在 $x = 0$ 处不可次微分

由定义 $g \in \partial f(x)$

$$f(y) \geq f(x) + g(y - x) \quad \forall y \in \text{dom } f$$

代入 $x = 0$, 即

$$f(y) \geq gy \iff g \leq -\sqrt{\frac{1}{y}} \quad \forall y \in \text{dom } f$$

得到 $g < -\infty$, 因此在 $x = 0$ 处不可次微分

1.3 次微分的单调性

凸函数的次微分是单调运算, 即

$$(\mathbf{u} - \mathbf{v})^T (\mathbf{x} - \mathbf{y}) \geq 0 \quad \forall \mathbf{x}, \mathbf{y}, \mathbf{u} \in \partial f(\mathbf{x}), \mathbf{v} \in \partial f(\mathbf{y})$$

证明. 由次微分的定义可得

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \mathbf{u}^T (\mathbf{y} - \mathbf{x}) \quad (1)$$

$$f(\mathbf{x}) \geq f(\mathbf{y}) + \mathbf{v}^T (\mathbf{x} - \mathbf{y}) \quad (2)$$

(1) + (2) 即得

$$(\mathbf{u} - \mathbf{v})^T (\mathbf{x} - \mathbf{y})$$

□

1.4 次梯度和水平集

1.5 次梯度计算运算规则

1.5.1 可导函数

如果函数 f 是可导的, 则

$$\partial f(\mathbf{x}) = \{\nabla f(\mathbf{x})\}$$

1.5.2 非负线性组合

如果 $f(\mathbf{x}) = \alpha_1 f_1(x) + \alpha_2 f_2(x)$, $\alpha_1, \alpha_2 \geq 0$, 则

$$\partial f(\mathbf{x}) = \alpha_1 \partial f_1(\mathbf{x}) + \alpha_2 \partial f_2(\mathbf{x})$$

注 2. 等式右边为集合的加法

1.5.3 对变量的仿射变换

如果 $f(\mathbf{x}) = h(A\mathbf{x} + \mathbf{b})$, 则

$$\partial f(\mathbf{x}) = A^T \partial h(A\mathbf{x} + \mathbf{b})$$

1.5.4 逐点最大

$$f(\mathbf{x}) = \max\{f_1(\mathbf{x}), \dots, f_m(\mathbf{x})\}$$

定义 $I(\mathbf{x}) = \{i | f_i(\mathbf{x}) = f(\mathbf{x})\}$

弱梯度计算规则: 选取任意 $k \in I(\mathbf{x})$, 计算 f_k 在点 \mathbf{x} 的其中一个梯度

强梯度计算规则: $\partial f(\mathbf{x}) = \text{conv}\{\bigcup_{i \in I(\mathbf{x})} \partial f_i(\mathbf{x})\}$ 。即 active 函数在 \mathbf{x} 点的次微分的并集的凸包, 如果 f_i 是可导的, 则 $\partial f(\mathbf{x}) = \text{conv}\{\nabla f_i(\mathbf{x}) | i \in I(\mathbf{x})\}$

例 5. $f(\mathbf{x}) = \max_{i=1, \dots, m} (\mathbf{a}_i^T \mathbf{x} + b_i)$, 则在 \mathbf{x} 点的次微分为

$$\partial f(\mathbf{x}) = \text{conv}\{\mathbf{a}_i | i \in I(\mathbf{x})\}$$

是一个多面体, 其中 $I(\mathbf{x}) = \{i | \mathbf{a}_i^T \mathbf{x} + b_i = f(\mathbf{x})\}$

1.5.5 最小化

已知函数 $f(\mathbf{x}) = \inf_{\mathbf{y}} h(\mathbf{x}, \mathbf{y})$, 并且 h 关于 (\mathbf{x}, \mathbf{y}) 联合凸。在 $\hat{\mathbf{x}}$ 处的次梯度的计算方式为

1. 假设最小值存在, 计算 $h(\hat{\mathbf{x}}, \mathbf{y})$ 的最小值 $\hat{\mathbf{y}}$

2. 计算次梯度 $(\mathbf{g}, \mathbf{0}) \in \partial h(\hat{\mathbf{x}}, \hat{\mathbf{y}})$

则 \mathbf{g} 即为 $f(\mathbf{x})$ 的一个次梯度

证明. 因为 $(\mathbf{g}, \mathbf{0}) \in \partial h(\hat{\mathbf{x}}, \hat{\mathbf{y}})$, 则由次梯度的定义可得, 对 $\forall \mathbf{x}, \mathbf{y}$ 成立

$$h(\mathbf{x}, \mathbf{y}) \geq h(\hat{\mathbf{x}}, \hat{\mathbf{y}}) + \mathbf{g}^T(\mathbf{x} - \hat{\mathbf{x}}) + \mathbf{0}^T(\mathbf{y} - \hat{\mathbf{y}})$$

又因为 $h(\hat{\mathbf{x}}, \hat{\mathbf{y}}) = \inf_{\mathbf{y}} h(\hat{\mathbf{x}}, \mathbf{y}) = f(\hat{\mathbf{x}})$, 上述不等式变为

$$h(\mathbf{x}, \mathbf{y}) \geq f(\hat{\mathbf{x}}) + \mathbf{g}^T(\mathbf{x} - \hat{\mathbf{x}})$$

对 $\forall \mathbf{x}, \mathbf{y}$ 成立, 因此

$$f(\mathbf{x}) = \inf_{\mathbf{y}} h(\mathbf{x}, \mathbf{y}) \geq f(\hat{\mathbf{x}}) + \mathbf{g}^T(\mathbf{x} - \hat{\mathbf{x}})$$

即 \mathbf{g} 是 $f(\mathbf{x})$ 的次梯度 □

例 6. 计算 $f(\mathbf{x}) = \inf_{\mathbf{y} \in C} \|\mathbf{x} - \mathbf{y}\|_2$, 其中 C 是闭凸集

$h(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2$, 当 $\hat{\mathbf{x}} \in C$ 时, $\hat{\mathbf{y}} = \arg \min_{\mathbf{y}} \|\hat{\mathbf{x}} - \mathbf{y}\| = \hat{\mathbf{x}}$, 此时 $h(\hat{\mathbf{x}}, \hat{\mathbf{y}}) = \|\hat{\mathbf{x}} - \hat{\mathbf{x}}\|_2 = 0$, 根据次梯度的定义

$$h(\mathbf{x}, \mathbf{y}) \geq h(\hat{\mathbf{x}}, \hat{\mathbf{y}}) + \mathbf{g}^T(\mathbf{x} - \hat{\mathbf{x}}) + \mathbf{0}^T(\mathbf{y} - \hat{\mathbf{y}}) \quad \forall \mathbf{x}, \mathbf{y}$$

即

$$\|\mathbf{x} - \mathbf{y}\|_2 \geq \mathbf{g}^T(\mathbf{x} - \hat{\mathbf{x}}) \quad \forall \mathbf{x}, \mathbf{y}$$

取 $\mathbf{g} = \mathbf{0}$, 此时 $\|\mathbf{x} - \mathbf{y}\|_2 \geq 0$ 对所有 \mathbf{x}, \mathbf{y} 恒成立

1.5.6 组合

已知函数 $f(\mathbf{x}) = h(f_1(\mathbf{x}), \dots, f_k(\mathbf{x}))$, 其中 h 是单调不减凸函数, f_i 也为凸函数。在 $\hat{\mathbf{x}}$ 处的次梯度的计算方式为

1. 计算 $\mathbf{z} \in \partial h(f_1(\hat{\mathbf{x}}), \dots, f_k(\hat{\mathbf{x}}))$ 和 $g_i \in \partial f_i(\hat{\mathbf{x}})$
2. 计算次梯度 $\mathbf{g} = z_1 g_1 + \dots + z_k g_k \in \partial f(\hat{\mathbf{x}})$

证明. 因为 $g_i \in \partial f_i(\hat{\mathbf{x}})$, 则

$$f_i(\mathbf{x}) \geq f_i(\hat{\mathbf{x}}) + \mathbf{g}_i^T(\mathbf{x} - \hat{\mathbf{x}})$$

又因为 f 单调不减, 因此

$$\begin{aligned} f(\mathbf{x}) &= h(f_1(\mathbf{x}), \dots, f_k(\mathbf{x})) \\ &\geq h(f_1(\mathbf{x}) + \mathbf{g}_1^T(\mathbf{x} - \hat{\mathbf{x}}), \dots, f_k(\mathbf{x}) + \mathbf{g}_k^T(\mathbf{x} - \hat{\mathbf{x}})) \end{aligned}$$

因为 $\mathbf{z} \in \partial h(f_1(\hat{\mathbf{x}}), \dots, f_k(\hat{\mathbf{x}}))$, 可以得到

$$\begin{aligned} h(f_1(\mathbf{x}) + \mathbf{g}_1^T(\mathbf{x} - \hat{\mathbf{x}}), \dots, f_k(\mathbf{x}) + \mathbf{g}_k^T(\mathbf{x} - \hat{\mathbf{x}})) &\geq h(f_1(\hat{\mathbf{x}}), \dots, f_k(\hat{\mathbf{x}})) + \mathbf{z}^T \begin{bmatrix} \mathbf{g}_1^T(\mathbf{x} - \hat{\mathbf{x}}) \\ \vdots \\ \mathbf{g}_k^T(\mathbf{x} - \hat{\mathbf{x}}) \end{bmatrix} \\ &= h(f_1(\hat{\mathbf{x}}), \dots, f_k(\hat{\mathbf{x}})) + (z_1 \mathbf{g}_1 + \dots + z_k \mathbf{g}_k)^T (\mathbf{x} - \hat{\mathbf{x}}) \\ &= f(\mathbf{x}) + \mathbf{g}^T (\mathbf{x} - \hat{\mathbf{x}}) \end{aligned}$$

因此 $\mathbf{g} = z_1 \mathbf{g}_1 + \dots + z_k \mathbf{g}_k \in \partial f(\hat{\mathbf{x}})$ □

1.5.7 最优值函数

凸优化问题

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & f_i(\mathbf{x}) \leq u_i, i = 1, \dots, m \\ & A\mathbf{x} = \mathbf{b} + \mathbf{v} \end{aligned}$$

最优值记为 $f(\mathbf{u}, \mathbf{v})$

假设 $f(\hat{\mathbf{u}}, \hat{\mathbf{v}})$ 是有限的, 并且强对偶成立, 原问题的对偶问题为

$$\begin{aligned} \max \inf_x \quad & \left(f_0(\mathbf{x}) + \sum_i \lambda_i (f_i(\mathbf{x}) - u_i) + \nu^T (A\mathbf{x} - \mathbf{b} - \mathbf{v}) \right) \\ \text{s.t.} \quad & \lambda \succeq 0 \end{aligned}$$

如果 $\hat{\lambda}, \hat{\nu}$ 是最优对偶变量, 则 $(-\hat{\lambda}, -\hat{\nu}) \in \partial f(\hat{\mathbf{u}}, \hat{\mathbf{v}})$

证明. 由弱对偶定理可以得到

$$\begin{aligned} f(\mathbf{u}, \mathbf{v}) &\geq \inf_{\mathbf{x}} \left(f_0(\mathbf{x}) + \sum_i \hat{\lambda}_i (f_i(\mathbf{x}) - u_i) + \hat{\nu}^T (A\mathbf{x} - \mathbf{b} - \mathbf{v}) \right) \\ &\geq \inf_{\mathbf{x}} \left(f_0(\mathbf{x}) + \sum_i \hat{\lambda}_i (f_i(\mathbf{x}) - \hat{u}_i) + \hat{\nu}^T (A\mathbf{x} - \mathbf{b} - \hat{\mathbf{v}}) \right) - \hat{\lambda}^T (\mathbf{u} - \hat{\mathbf{u}}) - \hat{\nu}^T (\mathbf{v} - \hat{\mathbf{v}}) \\ &= f(\hat{\mathbf{u}}, \hat{\mathbf{v}}) - \hat{\lambda}^T (\mathbf{u} - \hat{\mathbf{u}}) - \hat{\nu}^T (\mathbf{v} - \hat{\mathbf{v}}) \end{aligned}$$

由次梯度的定义可以得到 $(-\hat{\lambda}, -\hat{\nu}) \in \partial f(\hat{\mathbf{u}}, \hat{\mathbf{v}})$ □

1.5.8 方差

已知函数

$$f(\mathbf{x}) = \mathbb{E} h(\mathbf{x}, \mathbf{u})$$

其中 \mathbf{u} 是随机变量，且对任意 \mathbf{u} ， h 关于 \mathbf{x} 是凸的，在 $\hat{\mathbf{x}}$ 处的次梯度的计算方式为

1. 选择一个函数 $g(\mathbf{u}) \in \partial_{\mathbf{x}} h(\hat{\mathbf{x}}, \mathbf{u})$

2. $\mathbf{g} = \mathbb{E}_{\mathbf{u}} g(\mathbf{u}) \in \partial f(\hat{\mathbf{x}})$

证明. 因为 $g(\mathbf{u}) \in \partial_{\mathbf{x}} h(\hat{\mathbf{x}}, \mathbf{u})$ ，则

$$h(\mathbf{x}, \mathbf{u}) \geq h(\hat{\mathbf{x}}, \mathbf{u}) + g(\mathbf{u})^T (\mathbf{x} - \hat{\mathbf{x}})$$

因此

$$f(\mathbf{x}) = \mathbb{E} h(\mathbf{x}, \mathbf{u}) \geq \mathbb{E} (h(\hat{\mathbf{x}}, \mathbf{u}) + g^T(\mathbf{u})(\mathbf{x} - \hat{\mathbf{x}}))$$

由期望的性质得

$$\mathbb{E} (h(\hat{\mathbf{x}}, \mathbf{u}) + g^T(\mathbf{u})(\mathbf{x} - \hat{\mathbf{x}})) = f(\hat{\mathbf{x}}) + \mathbf{g}^T (\mathbf{x} - \hat{\mathbf{x}})$$

其中 $\mathbf{g} = \mathbb{E}_{\mathbf{u}} g(\mathbf{u})$ ，由梯度的定义可得 $\mathbf{g} \in \partial f(\hat{\mathbf{x}})$

□

2 对偶和最优性条件

2.1 无约束优化问题

定理 1. \mathbf{x}^* 最小化 $f(\mathbf{x})$ 当且仅当

$$\mathbf{0} \in \partial f(\mathbf{x}^*)$$

证明. \mathbf{x}^* 为最小值，则可以得到

$$\begin{aligned} f(\mathbf{y}) &\geq f(\mathbf{x}^*) + \mathbf{0}^T (\mathbf{y} - \mathbf{x}^*) \\ &= f(\mathbf{x}^*) + \mathbf{0}^T (\mathbf{y} - \mathbf{x}^*) \quad \forall \mathbf{y} \in \text{dom} f \end{aligned}$$

由次梯度的定义可以得到

$$\mathbf{0} \in \partial f(\mathbf{x}^*)$$

□

例 7.

2.2 约束优化问题

约束优化问题的最优解利用 KKT 条件进行刻画，有如下约束优化问题

$$\begin{aligned} \min f_0(\mathbf{x}) \\ s.t. f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m \end{aligned}$$

其中 $\text{dom } f_i = \mathbb{R}^n$ ，即 f_i 处处可次微分。如果强对偶条件成立，则 \mathbf{x}^*, λ^* 分别是原问题和对偶问题的最优解当且仅当

1. \mathbf{x}^* 是可行解

2. $\lambda^* \succeq 0$

3. $\lambda_i f_i(\mathbf{x}^*) = 0, i = 1, \dots, m$

4. \mathbf{x}^* 是 $L(\mathbf{x}, \lambda) = f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i^* f_i(\mathbf{x})$ 的最小值点，即

$$\mathbf{0} \in \partial f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i^* \partial f_i(\mathbf{x}^*)$$

3 方向导数

3.1 一般函数的方向导数

定义 3. 对于一般的函数 f ， $f(x)$ 在 y 方向上的导数为

$$\begin{aligned} f'(\mathbf{x}; \mathbf{y}) &= \lim_{\alpha \searrow 0} \frac{f(\mathbf{x} + \alpha \mathbf{y}) - f(\mathbf{x})}{\alpha} \\ &= \lim_{t \rightarrow \infty} \left(t f\left(\mathbf{x} + \frac{1}{t} \mathbf{y}\right) - t f(\mathbf{x}) \right) \end{aligned}$$

性质 3. $f'(\mathbf{x}; \mathbf{y})$ 关于 \mathbf{y} 是齐次的，即

$$f'(\mathbf{x}; \lambda \mathbf{y}) = \lambda f'(\mathbf{x}; \mathbf{y}) \quad \forall \lambda \geq 0$$

3.2 凸函数的方向导数

对于凸函数的方向导数，将一般函数方向导数定义中的 \lim 替换成 \inf ，即

$$\begin{aligned} f'(\mathbf{x}; \mathbf{y}) &= \inf_{\alpha \searrow 0} \frac{f(\mathbf{x} + \alpha \mathbf{y}) - f(\mathbf{x})}{\alpha} \\ &= \inf_{t \rightarrow \infty} \left(t f\left(\mathbf{x} + \frac{1}{t} \mathbf{y}\right) - t f(\mathbf{x}) \right) \end{aligned}$$

证明. 容易得到, $h(\mathbf{y}) = f(\mathbf{x} + \mathbf{y}) - f(\mathbf{x})$ 是关于 y 的凸函数, 且 $h(0) = 0$ 。
 下证 $th(\mathbf{y}/t)$ 关于 t 单调不增, 对任意的 $t > s > 0$ 总有

$$\begin{aligned} th(\mathbf{y}/t) - sh(\mathbf{y}/s) &= t[f(\mathbf{x} + \mathbf{y}/t) - f(\mathbf{x})] - s[f(\mathbf{x} + \mathbf{y}/s) - f(\mathbf{x})] \\ &= t \left[f(\mathbf{x} + \mathbf{y}/t) - \left(\frac{t-s}{t}f(\mathbf{x}) + \frac{s}{t}f(\mathbf{x} + \mathbf{y}/s) \right) \right] \end{aligned}$$

因为 $0 < \frac{t-s}{t} < 1, 0 < \frac{s}{t} < 1$, 且 $\frac{t-s}{t}\mathbf{x} + \frac{s}{t}\mathbf{x} + \mathbf{y}/s = \mathbf{x} + \mathbf{y}/t$, 由凸函数的定义可得

$$\frac{t-s}{t}f(\mathbf{x}) + \frac{s}{t}f(\mathbf{x} + \mathbf{y}/s) \geq f(\mathbf{x} + \mathbf{y}/t)$$

因此

$$\left[f(\mathbf{x} + \mathbf{y}/t) - \left(\frac{t-s}{t}f(\mathbf{x}) + \frac{s}{t}f(\mathbf{x} + \mathbf{y}/s) \right) \right] \leq 0$$

即 $th(\mathbf{y}/t)$ 关于 t 单调不增, 因此可以得到

$$\begin{aligned} f'(\mathbf{x}; \mathbf{y}) &= \lim_{t \rightarrow \infty} th(\mathbf{y}/t) = \inf_{t > 0} th(\mathbf{y}/t) \\ &= \inf_{t \rightarrow \infty} \left(tf(\mathbf{x} + \frac{1}{t}\mathbf{y}) - tf(\mathbf{x}) \right) \end{aligned}$$

□

性质 4. $f'(\mathbf{x}; \mathbf{y})$ 关于 \mathbf{y} 是凸的

性质 5. 由方向导数的定义, 可以得到

$$f(\mathbf{x} + \alpha\mathbf{y}) \geq f(\mathbf{x}) + \alpha f'(\mathbf{x}; \mathbf{y}) \quad \forall \alpha \geq 0$$

即 $f'(\mathbf{x}; \mathbf{y})$ 定义了 f 在 \mathbf{y} 方向上的下界

3.3 方向导数与次梯度

对于凸函数 $f, \mathbf{x} \in \text{int dom } f$, 方向导数与次微分具有如下关系

$$f'(\mathbf{x}; \mathbf{y}) = \sup_{\mathbf{g} \in \partial f(\mathbf{x})} \mathbf{g}^T \mathbf{y}$$

即 $f'(x; y)$ 是 $\partial f(\mathbf{x})$ 的支撑函数

对于可导函数, 则 $f'(\mathbf{x}; \mathbf{y}) = \nabla f(\mathbf{x})^T \mathbf{y}$

证明. 如果 $\mathbf{g} \in \partial f(\mathbf{x})$, 则由方向的定义可以得到

$$f'(\mathbf{x}; \mathbf{y}) \geq \inf_{\alpha > 0} \frac{f(\mathbf{x}) + \alpha \mathbf{g}^T \mathbf{y} - f(\mathbf{x})}{\alpha} = \mathbf{g}^T \mathbf{y}$$

下证存在 $\hat{\mathbf{g}} \in \partial f(\mathbf{x})$ 满足 $f'(\mathbf{x}; \mathbf{y}) = \hat{\mathbf{g}}^T \mathbf{y}$

设 $\hat{\mathbf{g}}$ 是 $f'(\mathbf{x}; \mathbf{y})$ 在 \mathbf{y} 方向的一个次梯度, 则由次梯度的定义和方向导数的性质可得

$$\lambda f'(\mathbf{x}; \mathbf{v}) = f'(\mathbf{x}; \lambda \mathbf{v}) \geq f'(\mathbf{x}; \mathbf{y}) + \hat{\mathbf{g}}^T (\lambda \mathbf{v} - \mathbf{y}), \quad \forall \mathbf{v}, \lambda \geq 0$$

令 $\lambda \rightarrow \infty$ 可以得到

$$f'(\mathbf{x}; \mathbf{v}) \geq \hat{\mathbf{g}}^T \mathbf{v}$$

有前面 $f'(\mathbf{x}; \mathbf{y})$ 定义了 f 在 \mathbf{y} 方向上的下界, 可以得到

$$f(\mathbf{x} + \mathbf{v}) \geq f(\mathbf{x}) + f'(\mathbf{x}; \mathbf{v}) \geq f(\mathbf{x}) + \hat{\mathbf{g}}^T \mathbf{v} \quad \forall \mathbf{v}$$

则由次梯度的定义可以得到

$$\hat{\mathbf{g}} \in \partial f(\mathbf{x})$$

令 $\lambda = 0$ 可以得到

$$f'(\mathbf{x}; \mathbf{y}) \leq \hat{\mathbf{g}}^T \mathbf{y}$$

□

3.4 下降方向和次梯度

定义 4. 如果 $f'(\mathbf{x}; \mathbf{y}) < 0$, 则 \mathbf{y} 是 f 在 \mathbf{x} 处的下降方向

注 3. 如果 $f(\mathbf{x}) \neq 0$, 则可微函数 f 的负梯度是下降方向, 但负的次梯度并不总是下降方向。比如 $f(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1| + 2|\mathbf{x}_2|$, $\mathbf{g} = (1, 2) \in \partial f(1, 0)$, 但是 $\mathbf{y} = -\mathbf{g} = (-1, -2)$ 不是 f 在 $(1, 0)$ 的下降方向